

Makine Öğrenmesi

Sınıflandırma ve Ağaçlar

İlker Birbil ve Utku Karaca

Erasmus Üniversitesi Rotterdam

İstanbul'da Makine Öğrenmesi

27 Ocak – 2 Şubat, 2020



Makine Öğrenmesi

```
graph TD; A[Makine Öğrenmesi] --> B[Doğrusal Bağlanım]; A --> C[Boyut Küçültme ve Düzenleştirme]; A --> D[Tekrar Örnekleme ve Model Değerlendirme]; A --> E[Sınıflandırma ve Ağaçlar]; A --> F[Güdümsüz Öğrenme]; A --> G[Yapay Sinir Ağları ve Derin Öğrenme];
```

Doğrusal Bağlanım


Boyut Küçültme
ve
Düzenleştirme

Tekrar Örnekleme
ve
Model Değerlendirme

Sınıflandırma
ve
Ağaçlar

Güdümsüz
Öğrenme

Yapay Sinir Ağları
ve
Derin Öğrenme



eğitim verisi
 $\{(x_i, y_i) : 1, \dots, n\}$

Lojistik Bağlanım (Logistic Regression)

X_1 : toplam harcama (bakiye)

X_2 : yıllık gelir

X_3 : öğrenci (1), öğrenci değil (0)




$$Y = \begin{cases} \text{kart borcu kalan (borçlu),} & 1; \\ \text{kart borcu kalmayan (borçsuz),} & 0. \end{cases}$$

$$p(X) = \mathbb{P}(Y = 1|X) \quad ?$$

$$p(X) = \mathbb{P}(Y = 1|X) > \tau$$



eşik değer (threshold)



$$p(X) = \mathbb{P}(Y = 1|X) \quad ?$$

$$p = 1$$

$$p(X) = \beta_0 + \beta_1 X \longrightarrow (-\infty, +\infty)$$

$$p(X) = \sigma(\beta_0 + \beta_1 X) \longrightarrow [0, 1]$$

?

Sigmoid Fonksiyonu


$$\sigma(y) = \frac{e^y}{1 + e^y}$$

Lojistik Fonksiyonu


$$p(X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}} \longrightarrow [0, 1]$$

$$p(X) = \mathbb{P}(Y = 1|X) \quad ?$$

$$p(X) = \beta_0 + \beta_1 X \longrightarrow (-\infty, +\infty) \quad p(X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}} \longrightarrow [0, 1]$$



Harcama



Harcama

$$\log \left(\underbrace{\frac{p(X)}{1 - p(X)}}_{\text{göreceli olasılıklar (odds)}} \right) = \beta_0 + \beta_1 X$$

göreceli olasılıklar (odds)

$$p > 1$$

$$p(X) = \sigma(\beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p)$$

Lojistik Fonksiyonu


$$p(X) = \frac{e^{\beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p}}{1 + e^{\beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p}}$$

$$\beta_0, \beta_1, \dots, \beta_p?$$



eğitim verisi

$$\{(x_i, y_i) : 1, \dots, n\}$$



Olabilirlik (Likelihood) Fonksiyonu

$$\ell(\beta_0, \dots, \beta_p) = \prod_{i: y_i = 1} p(x_i) \prod_{j: y_j = 0} (1 - p(x_j))$$

En Büyük (Maximum) Olabilirlik

$$\ell(\beta_0, \dots, \beta_p) = \prod_{i:y_i=1} p(x_i) \prod_{j:y_j=0} (1 - p(x_j))$$

$$\max_{\beta_0, \dots, \beta_p} \ell(\beta_0, \dots, \beta_p)$$



$$\max_{\beta_0, \dots, \beta_p} \log(\ell(\beta_0, \dots, \beta_p))$$



$$\max_{\beta_0, \dots, \beta_p} \sum_{i:y_i=1} p(x_i) + \sum_{j:y_j=0} (1 - p(x_j))$$



İçbükey Fonksiyon



$$\hat{\beta}_0, \dots, \hat{\beta}_p$$

$$p = 1$$

	Katsayı	St. Hata	Z istatistiği	<i>p</i> değeri
Kesme nok.	-3,5041	0,0707	-49,55	< 0,0001
Öğrenci (1)	0,4049	0,1150	3,52	0,0004

$$p > 1$$

	Katsayı	St. Hata	Z istatistiği	<i>p</i> değeri
Kesme nok.	-10,8690	0,4923	-22,08	< 0,0001
Harcama	0,0057	0,0002	24,74	< 0,0001
Gelir	0,0030	0,0082	0,37	0,7115
Öğrenci (1)	-0,6468	0,2362	-2,74	0,0062

Parazit Etkisi (Confounding Effect)

Tahmin Yapma

	Katsayı	St. Hata	Z istatistiği	<i>p</i> değeri
Kesme nok.	-10,8690	0,4923	-22,08	< 0,0001
Harcama	0,0057	0,0002	24,74	< 0,0001
Gelir	0,0030	0,0082	0,37	0,7115
Öğrenci (1)	-0,6468	0,2362	-2,74	0,0062

$$X = \begin{bmatrix} 1.500 \\ 40.000 \\ 1 \end{bmatrix}$$

$$p(X) = \frac{e^{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p}}{1 + e^{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p}}$$

$$\hat{p}(X) = \frac{e^{-10,869 + 0,0057 \times 1.500 + 0,003 \times 40 - 0,6468 \times 1}}{1 + e^{-10,869 + 0,0057 \times 1.500 + 0,003 \times 40 - 0,6468 \times 1}} = 0.058$$

Doğrusal Ayrımlayıcı Çözümleme (Linear Discriminant Analysis - LDA)

$$\mathbb{P}(Y = k|X = x) \quad \longleftrightarrow \quad \mathbb{P}(X = x|Y = k)$$



Bayes Kuramı

$$\mathbb{P}(Y = k|X = x) = \frac{\overbrace{\mathbb{P}(Y = k)\mathbb{P}(X = x|Y = k)}^{\pi_k \quad f_k(x)}}{\sum_{l=1}^K \mathbb{P}(Y = l)\mathbb{P}(X = x|Y = l)}$$

Ardıl Olasılık (Posterior Probability)

$$p_k(x) = \frac{\pi_k f_k(x)}{\sum_{l=1}^K \pi_l f_l(x)}$$

π_k ?

$f_k(x)$?

$$f_k(x) \text{ ?}$$


$$p = 1$$

$$\mathbb{P}(Y = k|X = x) = \frac{\overbrace{\mathbb{P}(Y = k)\mathbb{P}(X = x|Y = k)}^{\pi_k f_k(x)}}{\sum_{l=1}^K \mathbb{P}(Y = l)\mathbb{P}(X = x|Y = l)}$$

Kabul 1: $X \sim N(\mu, \sigma)$

$$f_k(x) = \frac{1}{\sqrt{2\pi\sigma_k}} \exp\left(-\frac{1}{2\sigma_k^2}(x - \mu_k)^2\right)$$

Kabul 2: $\sigma_1^2 = \sigma_2^2 = \dots = \sigma_K^2 = \sigma^2$



$$p_k(x) = \frac{\pi_k \frac{1}{\sqrt{2\pi\sigma}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu_k)^2\right)}{\sum_{l=1}^K \pi_l \frac{1}{\sqrt{2\pi\sigma}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu_l)^2\right)}$$

$$p_k(x) = \frac{\pi_k \frac{1}{\sqrt{2\pi\sigma}} \exp\left(-\frac{1}{2\sigma^2} (x - \mu_k)^2\right)}{\sum_{l=1}^K \pi_l \frac{1}{\sqrt{2\pi\sigma}} \exp\left(-\frac{1}{2\sigma^2} (x - \mu_l)^2\right)}$$

$$\log(p_k(x)) = \log\left(\frac{\pi_k \frac{1}{\sqrt{2\pi\sigma}} \exp\left(-\frac{1}{2\sigma^2} (x - \mu_k)^2\right)}{\sum_{l=1}^K \pi_l \frac{1}{\sqrt{2\pi\sigma}} \exp\left(-\frac{1}{2\sigma^2} (x - \mu_l)^2\right)}\right)$$

⋮

$$= \underbrace{x \frac{\mu_k}{\sigma^2} - \frac{\mu_k^2}{2\sigma^2} + \log(\pi_k)}_{\delta_k(x)} - C$$

k 'den bağımsız
sabit terim

$$\delta_k(x) = x \frac{\mu_k}{\sigma^2} - \frac{\mu_k^2}{2\sigma^2} + \log(\pi_k)$$

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i:y_i=k} x_i \quad \hat{\sigma}^2 = \frac{1}{n-K} \sum_{k=1}^K \sum_{i:y_i=k} (x_i - \hat{\mu}_k)^2 \quad \hat{\pi}_k = \frac{n_k}{n}$$

k sınıfından
veri sayısı

$$\hat{\delta}_k(x) = x \frac{\hat{\mu}_k}{\hat{\sigma}^2} - \frac{\hat{\mu}_k^2}{2\hat{\sigma}^2} + \log(\hat{\pi}_k)$$

$$X = x$$


$$\hat{\delta}_k(x) \uparrow \uparrow$$

$$Y = k$$

$$\boxed{p > 1} \quad X = (X_1, X_2, \dots, X_p)$$

Kabul 1: $X \sim N(\mu, \Sigma)$

$$f_k(x) = \frac{1}{(2\pi)^{p/2} |\Sigma_k|^{1/2}} \exp \left(-\frac{1}{2} (x - \mu_k)^\top \Sigma_k^{-1} (x - \mu_k) \right)$$



Kabul 2: $\Sigma_1 = \Sigma_2 = \dots = \Sigma_K = \Sigma$

$$\delta_k(x) = x^\top \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^\top \Sigma^{-1} \mu_k + \log(\pi_k)$$

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i:y_i=k} x_i \qquad \hat{\pi}_k = \frac{n_k}{n}$$

$$\hat{\Sigma} = \frac{1}{n-K} \sum_{k=1}^K \sum_{i:y_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^\top$$

$$\hat{\delta}_k(x) = x^\top \hat{\Sigma}^{-1} \hat{\mu}_k - \frac{1}{2} \hat{\mu}_k^\top \hat{\Sigma}^{-1} \hat{\mu}_k + \log(\hat{\pi}_k)$$

$$X = x$$

$$\hat{\delta}_k(x) \quad \uparrow \uparrow$$

$$Y = k$$

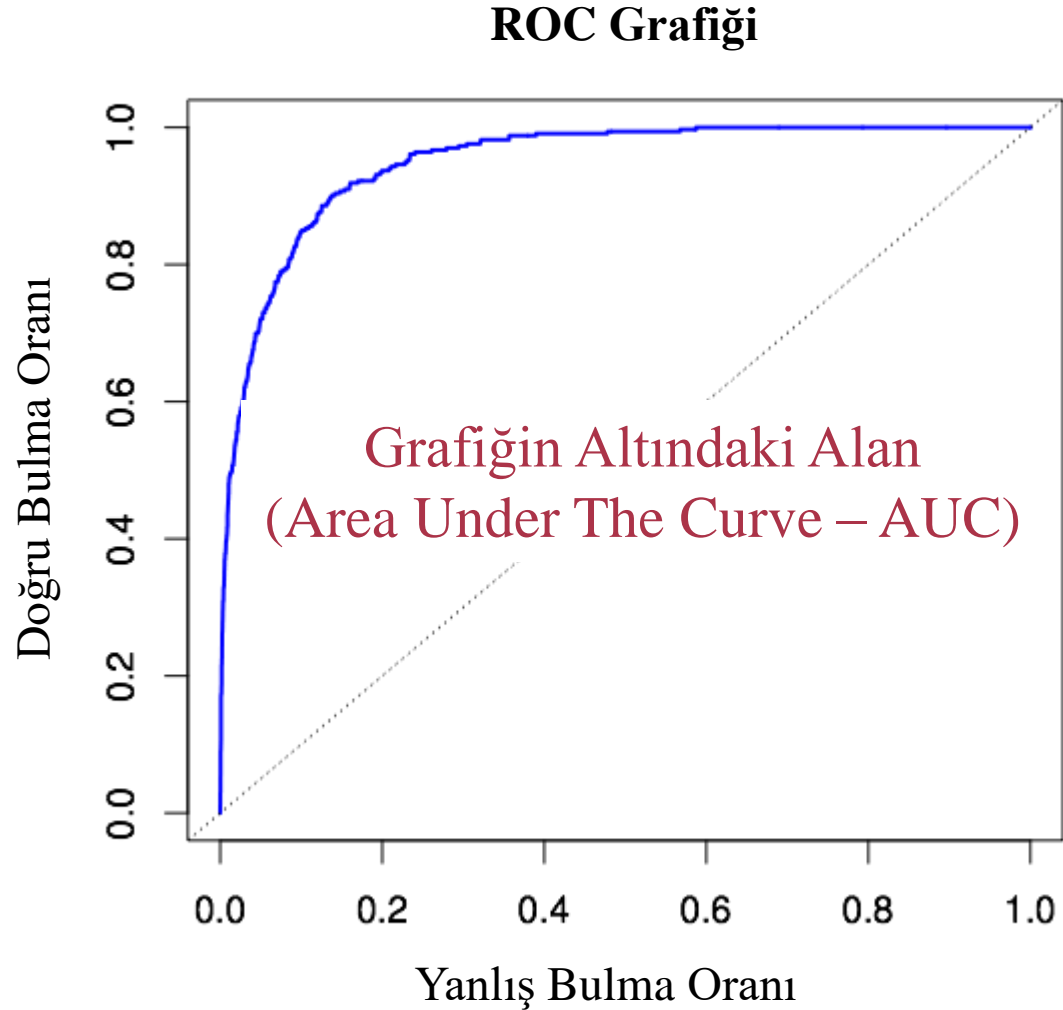
$$p(X) = \mathbb{P}(Y = 1|X) > \tau$$

$\tau = 0.5$		Gerçek		
		Borçsuz	Borçlu	Toplam
Tahmin	Borçsuz	9.644	252	9.896
	Borçlu	23	81	104
	Toplam	9.667	333	10.000

$\tau = 0.2$		Gerçek		
		Borçsuz	Borçlu	Toplam
Tahmin	Borçsuz	9.432	138	9.570
	Borçlu	235	195	430
	Toplam	9.667	333	10.000

ROC* Grafiđi

(Karar Deđerlendirme Grafiđi)



* Receiver Operating Characteristics

Hata Matrisi (Confusion Matrix)

		Tahmin Edilen Sınıf		
		-	+	Toplam
Gerçek Sınıf	-	Gerçek Negatif (GN)	Yanlış Pozitif (YP)	N
	+	Yanlış Negatif (YN)	Gerçek Pozitif (GP)	P
	Toplam	N*	P*	

		Tahmin Edilen Sınıf		
		-	+	Toplam
Gerçek Sınıf	-	GN	YP	N
	+	YN	GP	P
	Toplam	N*	P*	

İsim	Hesap	Eş Anlam
Yanlış Bulma Oranı^a	YP/N	birinci tip hata (type I error), 1 – özgüllük (specifity)
Doğru Bulma Oranı^b	GP/P	1 – ikinci tip hata (type II error), üs, duyarlılık (sensitivity), doğruluk (recall)
Pozitif Tahmin Değeri^c	GP/P*	kesinlik (precision), 1 – yanlış keşif oranı (false discovery proportion)
Negatif Tahmin Değeri^d	GN/N*	

^a False Positive Rate

^b True Positive Rate


^c Positive Predictive Value

^d Negative Predictive Value

Karar Ağaçları (Decision Trees)


Amaç: Değişkenler uzayını basit alt bölgelere ayırmak

Bağlanım Ağaçları
Sınıflandırma Ağaçları




Topluluk Yöntemleri

Torbalama (Bagging) ve
Rastgele Ormanlar (Random Forests)





Takviye (Boosting)



Örnek Ağaç

Bir beyzbol oyuncusunun maaşının yaptığı vuruş ve oynadığı toplam yıla göre tahmin edilmesi



Bağlanım Ağaçları

$$X_1, X_2, \dots, X_p \xrightarrow{\text{Çakışmayan bölgeler}} R_1, R_2, \dots, R_J$$

Tahmin: R_j bölgesindeki eğitim verisinin çıktı değerlerinin (y_i) ortalaması

$$R_1, R_2, \dots, R_J \quad ?$$

Amaç: KKT değerinin en küçük olduğu bölgelerin bulunması

$$\sum_{j=1}^J \sum_{i \in R_j} (y_i - \hat{y}_{R_j})^2$$

\hat{y}_{R_j} : R_j bölgesindeki çıktıların ortalaması

Bağlanım Ağaçları





Özyinelemeli İkili Ayırma (Recursive Binary Splitting)

$$R_1(j, s) = \{X | X_j < s\} \quad R_2(j, s) = \{X | X_j \geq s\}$$

Aşağıdaki ifadeyi en küçükleyen j ve s değerlerini bul

$$\sum_{i: x_i \in R_1(j, s)} (y_i - \hat{y}_{R_1})^2 + \sum_{i: x_i \in R_2(j, s)} (y_i - \hat{y}_{R_2})^2$$

Terminal düğümde çok az veri noktası kalınca **dur!**



Bağlanım Ağaçları

Ağaç Budama (Tree Pruning)

Amaç: Ağacın tamamı ya da büyük kısmı oluşunca ortaya çıkan aşırı öğrenmenin önüne geçmek (düşük *test* hatası)

$$\sum_{m=1}^{|T|} \sum_{i: x_i \in R_m} (y_i - \hat{y}_{R_m})^2 + \alpha |T|$$

$T \subset T_0$: alt ağaç (subtree)

$|T|$: T ağacındaki terminal düğüm sayısı

R_m : m . terminal düğüme karşılık gelen bölge

α : sabit parametre

$\alpha \uparrow$

$|T| \downarrow$

α parametresini bulmak için k -katlı çapraz geçerlilik sınaması yapılır


Sınıflandırma Ağaçları

Bağlanım ağaçlarına çok benzer şekilde ilerlenir ancak alt bölgenin *saflık* derecesine bağlı bir hata ölçüsü kullanılır

\hat{p}_{mk} : m . bölgedeki eğitim verisindeki k . sınıftan olanların oranı


Sınıflandırma Hata Oranı

$$E = 1 - \max_k \{\hat{p}_{mk}\}$$




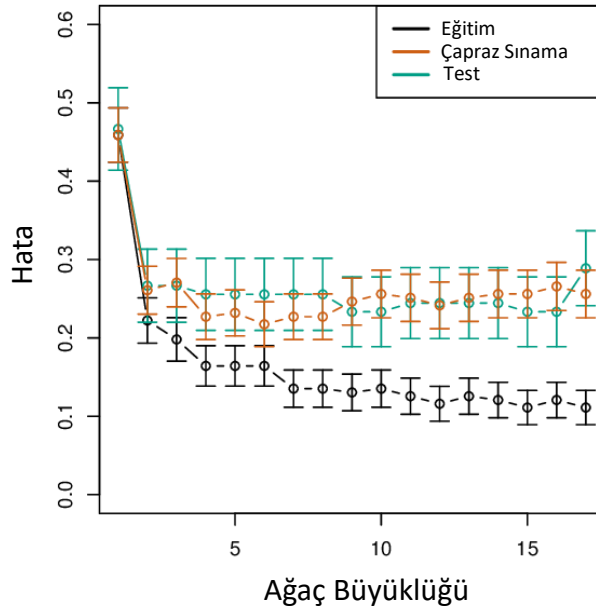

Entropi

$$D = - \sum_{k=1}^K \hat{p}_{mk} \log \hat{p}_{mk}$$



Gini İndeksi


$$G = \sum_{k=1}^K \hat{p}_{mk}(1 - \hat{p}_{mk})$$



Topluluk Yöntemleri

Torbalama

Amaç: Varyansı düşürmek için zorlama tekniğini kullanarak birkaç tane büyük ağaç oluşturulur ve onların tahminlerinin ortalaması (bağlanım) ya da çoğunlukta olan sınıf (sınıflandırma) hesaplanır.



Bağlanım

B : farklı eğitim kümesi sayısı

$\hat{f}^{*b}(x)$: b . eğitim kümesi ile elde edilen tahmin

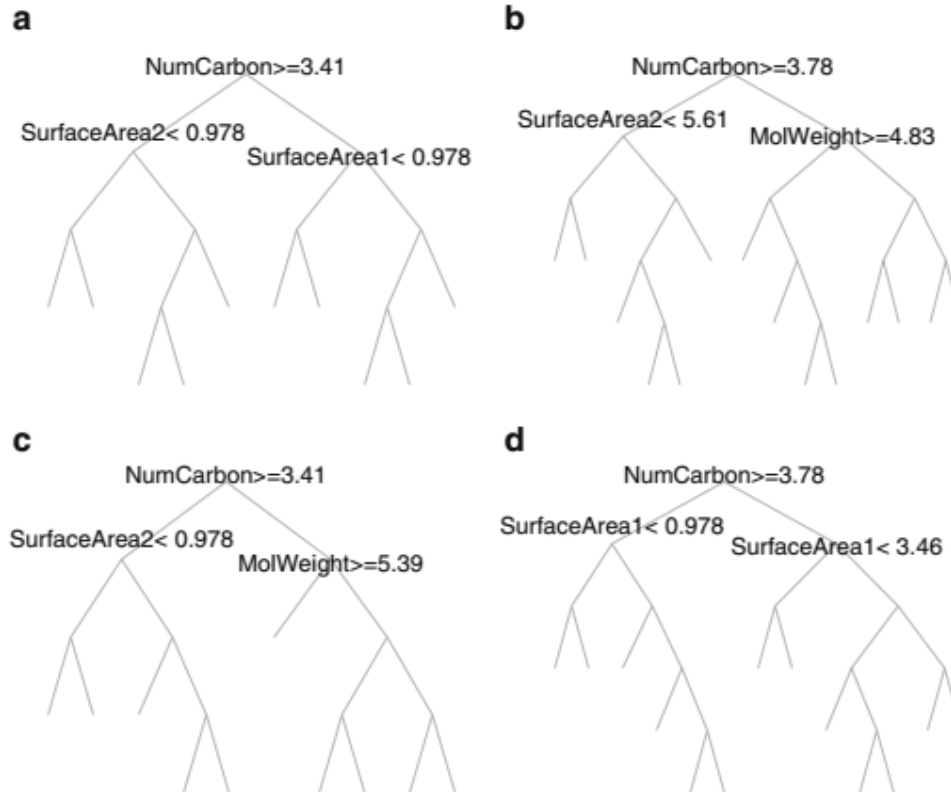
$$\hat{f}_{\text{bag}}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{*b}(x)$$

Topluluk Yöntemleri

Rastgele Ormanlar

Amaç: Ağaçlar arasındaki korelasyonu azaltmak için dalları ayırırken tüm değişkenler yerine sadece rassal sayıda değişkeni kullanmak


Neden?



Topluluk Yöntemleri

Takviye

Fikir: Fazla etkin olmayan sınıflandırıcıları, ağırlıklı veri örnekleme tekniğini kullanarak bir araya getirerek daha etkin bir sınıflandırıcı elde etmek



Güncelleme Kuralı: Yanlış sınıflandırılan veri noktalarının ağırlıklarını artır

Ensemble Methods

AdaBoost – İkili Sınıflandırma $\{+1, -1\}$

Her bir veri satırı başlangıçta aynı ağırlığa sahip: $(1/n)$

for $k=1$ to K **do**

ağırlıklı verileri kullanarak d dallı bir ağaç eğit ve yanlış sınıflandırma hatasını hesapla (ϵ_k)

Ağırlık değerini hesapla $\ln \frac{1 - \epsilon_k}{\epsilon_k}$

Ağırlıklı verileri güncelle – yanlış sınıflandırılan verilere daha fazla ağırlık ver

end

Her bir veri için k . aşamadaki değer ile k . model tahminini çarparak takviyeli sınıflandırıcının tahminlerini hesapla ve bu miktarları k 'ye ekle. Eğer toplam pozitif ise veriyi $+1$ olarak sınıflandır, değilse -1 .

Kitaptaki Algoritma 8.2 **bağlanım ağaçları** için takviye örneği veriyor.

Topluluk Yöntemleri

AdaBoost – İkili Sınıflandırma $\{+1, -1\}$

Algoritma 1: AdaBoost

- 1 Başlangıç ağırlıklarını belirle: $w_i^1 = \frac{1}{n}$, $i = 1, \dots, n$
- 2 **for** $k = 1, \dots, K$ **do**
- 3 $y_k(x)$ sınıflandırıcısını şu ağırlıklı sınıflandırma hata fonksiyonu ile eğit:

$$\sum_{i=1}^n w_i^k I(y_k(x_i) \neq y_i)$$

Yanlış sınıflandırılan veri noktalarının oransal ağırlığını hesapla:


$$\varepsilon^k = \frac{\sum_{i=1}^n w_i^k I(y_k(x_i) \neq y_i)}{\sum_{i=1}^n w_i^k}$$

- 4 Güncelleme parametresini belirle: $\alpha_k = \ln \frac{1-\varepsilon_k}{\varepsilon_k}$
 - 5 Ağırlıkları güncelle: $w_i^{k+1} = w_i^k e^{\alpha_k I(y_k(x_i) \neq y_i)}$, $i = 1, \dots, n$
 - 6 **Çıktı:** $\sum_{k=1}^K \alpha_k y_k(x)$ değerinin işareti (+1 ya da -1)
-

(AdaBoost Özeti)

Topluluk Yöntemleri

- Takviye ve torbalama yöntemleri başka yöntemler ile de uygulanabilirler
- Torbalama yöntemi paralel uygulama için son derece uygun olmasına rağmen, takviye yöntemi sıralı yapısı nedeniyle paralelleştirmeye uygun değildir
- Topluluk yöntemleri ile elde edilen modeli yorumlamak güçtür
- Değişken önemini (variable importance) gösteren grafikler kullanılabilir



Bir **değişkenin önemi** Gini indeksinde ya da entropide elde ettiği ortalama azaltmaya göre belirlenir. Daha sonra değişkenler bu önem sırasına göre oranlanarak sıralanır.

Pratikte

```
# Required packages
from sklearn.tree import DecisionTreeClassifier
from sklearn.datasets import make_classification
from sklearn.ensemble import BaggingClassifier
from sklearn.ensemble import RandomForestClassifier
from sklearn.ensemble import AdaBoostClassifier

# Generate and extract features and target data
X, y = make_classification(n_samples=1000,
                          n_features=4,
                          n_informative=2,
                          n_redundant=0,
                          random_state=0,
                          shuffle=False)

# Create decision tree and train it
DTClassifier = DecisionTreeClassifier(criterion = 'gini',
                                     splitter = 'best',
                                     max_depth = None,
                                     min_samples_leaf = 5)

DTClassifier.fit(X, y)
DTClassifier.score(X, y)

# Bagging
bagging = BaggingClassifier(DTClassifier,
                            n_estimators = 20,
                            max_samples = 1.0,
                            bootstrap = True,
                            bootstrap_features = False)

bagging.fit(X, y)
bagging.score(X, y)

# Random Forest
RF = RandomForestClassifier(criterion = 'gini',
                           n_estimators=10,
                           max_depth=None,
                           min_samples_leaf = 5,
                           random_state=0)

RF.fit(X,y)
RF.score(X,y)

# Adaboost
ABC = AdaBoostClassifier(n_estimators=100, random_state=0)
ABC.fit(X, y)
ABC.score(X,y)
```

paketler ve fonksiyonlar

verinin yaratılması

karar ağacı uydurumu ve
performansının raporlanması

topluluk yöntemleri

torbalama yöntemi kullanımı
ve performansının
raporlanması

```
...: [DTClassifier.score(X, y),
...:  bagging.score(X, y),
...:  RF.score(X,y),
...:  ABC.score(X,y)]
out[2]: [0.97, 0.973, 0.975, 0.983]
```

rastgele ormanlar yöntemi
kullanımı ve performansının
raporlanması

AdaBoost yönteminin kullanımı ve
performansının raporlanması

Destek Vektör Makineleri - DVM (Support Vector Machines - SVM)

$$(x_i, y_i), \quad i = 1, 2, \dots, n$$



$$x_i \in \mathbb{R}^p \qquad y_i \in \{-1, +1\}$$

Fikir: Bir düzlem (hyperplane) yardımıyla veri noktalarını iki sınıfa ayırmak


Düzlem

$$\{X \in \mathbb{R}^p : \beta^\top X + \beta_0 = 0, \beta \in \mathbb{R}^p, \beta_0 \in \mathbb{R}\}$$

Tam Ayrıştırılabilir Veri



Tam Ayrıştırılabilir Veri




Tam Ayrıştırılabilir Veri

Amaç: β ve Δ parametrelerini,

$$\beta^\top X + \beta_0 - \Delta = 0 \quad \text{ve} \quad \beta^\top X + \beta_0 + \Delta = 0$$

ile gösterilen iki düzlem arasındaki mesafe en fazla olacak şekilde seçmek

Eşitliklerin her iki tarafı Δ değerine bölünüp, $\Delta = 1$ olarak alınabilir


$$\begin{array}{lcl} (x_i, y_i) & \begin{array}{l} \nearrow \\ \searrow \end{array} & \begin{array}{l} y_i = 1 \\ y_i = -1 \end{array} \end{array} \quad \begin{array}{l} \longrightarrow \\ \longrightarrow \end{array} \quad \begin{array}{l} \beta^\top x_i + \beta_0 - 1 \geq 0 \\ \beta^\top x_i + \beta_0 + 1 \leq 0 \end{array}$$

$$y_i(\beta^\top x_i + \beta_0) \geq 1$$

Tam Ayrıştırılabilir Veri

Amaç: β ve Δ parametrelerini,

$$\beta^T X + \beta_0 - \Delta = 0 \quad \text{ve} \quad \beta^T X + \beta_0 + \Delta = 0$$

ile gösterilen iki düzlem arasındaki mesafe en fazla olacak şekilde seçmek



$$\beta = (\beta_1, \beta_2)^T$$

β : alt uzaya dik doğrultu

$$\beta^T x = 0$$

Ayrıca β vektörü

$$\beta^T x + \beta_0 = 1$$

ve

$$\beta^T x + \beta_0 = -1$$



düzlemlerine de dik

Tam Ayrıştırılabilir Veri

Amaç: β ve Δ parametrelerini,

$$\beta^\top X + \beta_0 - \Delta = 0 \quad \text{ve} \quad \beta^\top X + \beta_0 + \Delta = 0$$

ile gösterilen iki düzlem arasındaki mesafe en fazla olacak şekilde seçmek



İki düzlem arasındaki mesafe: $\frac{1 - \beta_0}{\|\beta\|} - \frac{-1 - \beta_0}{\|\beta\|} = \frac{2}{\|\beta\|}$

Tam Ayrıştırılabilir Veri

Amaç: β ve Δ parametrelerini,

$$\beta^\top X + \beta_0 - \Delta = 0 \quad \text{ve} \quad \beta^\top X + \beta_0 + \Delta = 0$$

ile gösterilen iki düzlem arasındaki mesafe en fazla olacak şekilde seçmek



$$\begin{aligned} &\text{enbüyük} && \frac{2}{\|\beta\|} \\ &\text{öyle ki} && y_i(\beta^\top x_i + \beta_0) \geq 1, \quad i = 1, \dots, n \end{aligned}$$

$$\begin{aligned} &\equiv && \frac{1}{2} \|\beta\| \\ &\text{enküçük} && \\ &\text{öyle ki} && y_i(\beta^\top x_i + \beta_0) \geq 1, \quad i = 1, \dots, n \end{aligned}$$


$$\begin{aligned} &\equiv && \frac{1}{2} \beta^\top \beta \\ &\text{enküçük} && \\ &\text{öyle ki} && y_i(\beta^\top x_i + \beta_0) \geq 1, \quad i = 1, \dots, n \end{aligned}$$

Bu matematiksel model, karesel ve **dışbükey** amaç fonksiyonu ile **doğrusal** kısıtlardan oluşuyor. Bu yapıdaki modellere **karesel programlama** (quadratic programming) modelleri denir.

Tam Ayrıştırılabilir Veri




Tam Ayrıştırılmayan Veri



- (A) $y_i(\beta^T x_i + \beta_0) \geq 1 - \varepsilon, \quad \varepsilon = 0$
- (B) $y_i(\beta^T x_i + \beta_0) \geq 1 - \varepsilon, \quad 0 < \varepsilon < 1$
- (C) $y_i(\beta^T x_i + \beta_0) \geq 1 - \varepsilon, \quad \varepsilon \geq 1$

Tam Ayrıştırılamayan Veri




(A) $y_i(\beta^\top x_i + \beta_0) \geq 1 - \varepsilon, \quad \varepsilon = 0$

(B) $y_i(\beta^\top x_i + \beta_0) \geq 1 - \varepsilon, \quad 0 < \varepsilon < 1$

(C) $y_i(\beta^\top x_i + \beta_0) \geq 1 - \varepsilon, \quad \varepsilon \geq 1$

Tam Ayrıştırılmayan Veri




**esneme payı
(soft margin)**

$$y_i(\beta^T x_i + \beta_0) \geq 1 - \varepsilon, \quad \varepsilon = 0$$

$$y_i(\beta^T x_i + \beta_0) \geq 1 - \varepsilon, \quad 0 < \varepsilon < 1$$

$$y_i(\beta^T x_i + \beta_0) \geq 1 - \varepsilon, \quad \varepsilon \geq 1$$

Tam Ayrıştırılamayan Veri







$$\begin{aligned} y_i(\beta^T x_i + \beta_0) &\geq 1 - \varepsilon, \quad \varepsilon = 0 \\ y_i(\beta^T x_i + \beta_0) &\geq 1 - \varepsilon, \quad 0 < \varepsilon < 1 \\ y_i(\beta^T x_i + \beta_0) &\geq 1 - \varepsilon, \quad \varepsilon \geq 1 \end{aligned}$$

enküçükle
öyle ki



$$\begin{aligned} &\frac{1}{2} \beta^T \beta + c \sum_{i=1}^n \varepsilon_i^d \\ &y_i(\beta^T x_i + \beta_0) \geq 1 - \varepsilon_i, \quad i = 1, \dots, n \\ &\varepsilon_i \geq 0, \quad i = 1, \dots, n \end{aligned}$$

Burada c parametresi çapraz geçerlilik sınaması ile belirlenebilir
(uygulamalarda $d = 1$ ve $d = 2$ değerleri sık kullanılır)

Tam Ayrıştırılmayan Veri



Çekirdekler (Kernels)



Çekirdekler

enküçükle $\frac{1}{2}\beta^\top\beta$
öyle ki $y_i(\beta^\top x_i + \beta_0) \geq 1, \quad i = 1, \dots, n$

Lagrange
çarpanları

Lagrange
Fonksiyonu

$$\mathcal{L}(\beta, \beta_0; \alpha) = \frac{1}{2}\beta^\top\beta - \sum_{i \in \mathcal{A}} \alpha_i (y_i(\beta^\top x_i + \beta_0) - 1)$$

aktif kısıtlar kümesi

Optimallik
Şartları

$$\left\{ \begin{array}{l} \nabla_{\beta} \mathcal{L}(\beta, \beta_0; \alpha) = \beta - \sum_{i \in \mathcal{A}} \alpha_i y_i x_i = 0 \implies \beta = \sum_{i \in \mathcal{A}} \alpha_i y_i x_i \\ \frac{\partial \mathcal{L}(\beta, \beta_0; \alpha)}{\partial \beta_0} = - \sum_{i \in \mathcal{A}} \alpha_i y_i = 0 \implies \sum_{i \in \mathcal{A}} \alpha_i y_i = 0 \end{array} \right.$$

$$\begin{aligned} \mathcal{L}(\beta, \beta_0; \alpha) &= \frac{1}{2}(\sum_{i \in \mathcal{A}} \alpha_i y_i x_i)^\top (\sum_{j \in \mathcal{A}} \alpha_j y_j x_j) - (\sum_{i \in \mathcal{A}} \alpha_i y_i (\sum_{j \in \mathcal{A}} \alpha_j y_j x_j)^\top x_i) \\ &\quad - \sum_{i \in \mathcal{A}} \alpha_i y_i \beta_0 + \sum_{i \in \mathcal{A}} \alpha_i \\ &= \sum_{i \in \mathcal{A}} \alpha_i - \frac{1}{2} \sum_{i \in \mathcal{A}} \sum_{j \in \mathcal{A}} \alpha_i \alpha_j y_i y_j \boxed{x_i^\top x_j} ! \end{aligned}$$

Çekirdekler

$$\mathcal{L}(\beta, \beta_0; \alpha) = \sum_{i \in \mathcal{A}} \alpha_i - \frac{1}{2} \sum_{i \in \mathcal{A}} \sum_{j \in \mathcal{A}} \alpha_i \alpha_j y_i y_j \boxed{x_i^\top x_j}^*$$

tek yapmamız gereken
bu iç çarpımları hesaplamak



Fikir: İç çarpım hesabını daha yüksek boyutlu uzayda iki veri arasındaki benzerliği ölçen bir çekirdek ile değiştirmek

Doğrusal Çekirdek* $K(x_i, x_j) = x_i^\top x_j$

Polinom Çekirdek $K(x_i, x_j) = (1 + x_i^\top x_j)^d$

Radyal Çekirdek $K(x_i, x_j) = e^{-\gamma \|x_i - x_j\|^2}, \gamma > 0$


Çekirdekler



Çekirdekler

$$\varphi : \mathbb{R}^p \rightarrow \mathbb{R}^q$$

$$K(x_i, x_j) = \varphi(x_i)^\top \varphi(x_j)$$



Çekirdekler

$$x_i, x_j \in \mathbb{R}^2$$
$$d = 2$$

$$\text{Polinom çekirdek: } K(x_i, x_j) = (1 + x_i^\top x_j)^d$$

$$K(x_i, x_j) = (1 + x_i^\top x_j)^2 = 1 + x_{i1}^2 x_{j1}^2 + x_{i2}^2 x_{j2}^2 + 2x_{i1} x_{j1} + 2x_{i2} x_{j2} + 2x_{i1} x_{i2} x_{j1} x_{j2}$$


$$\varphi : \mathbb{R}^2 \rightarrow \mathbb{R}^6$$

$$\varphi(x_i) = (1, x_{i1}^2, x_{i2}^2, \sqrt{2}x_{i1}, \sqrt{2}x_{i2}, \sqrt{2}x_{i1}x_{i2})^\top$$

$$K(x_i, x_j) = \varphi(x_i)^\top \varphi(x_j) = (1 + x_i^\top x_j)^2$$


Çoklu Sınıf

Tüm Çiftler



x_0 en sık atandığı sınıfta kabul edilir

Biri Diğerlerine Karşı



$$\beta_0^{(k)} + \beta^{(k)\top} x_0$$

$$\left[\begin{array}{c} \beta_0^{(1)} + \beta^{(1)\top} x_0 \\ \beta_0^{(2)} + \beta^{(2)\top} x_0 \\ \vdots \\ \beta_0^{(K)} + \beta^{(K)\top} x_0 \end{array} \right] \left. \vphantom{\begin{array}{c} \beta_0^{(1)} + \beta^{(1)\top} x_0 \\ \beta_0^{(2)} + \beta^{(2)\top} x_0 \\ \vdots \\ \beta_0^{(K)} + \beta^{(K)\top} x_0 \end{array}} \right\} \begin{array}{l} x_0 \text{ en yüksek} \\ \text{değeri alan} \\ \text{sınıfa atanır} \end{array}$$

Özet

- Lojistik Bağlanım
- Doğrusal Ayrımlayıcı Çözümleme
- Sonuçların değerlendirilmesi
- Karar Ağaçları
- Bağlanım ve Sınıflandırma Ağaçları
- Topluluk yöntemleri
- Destek Vektör Makineleri